


Fuzzy systémy


Základné pojmy
(fuzzy množina & lingvistická premenná)

Základné koncepty teórie fuzzy množín

- Fuzzy množina (FM)
- Lingvistická (jazyková) premenná (LP)
- Princíp rozšírenia (*fuzzy aritmetika*)
- Fuzzy relácia
- Fuzzy granule
- Počítanie so slovami
- ...



Fuzzy množina




$$A = \{(u, \mu_A(u)), u \in U\}$$

U – univerzum

A – názov FM


$\mu_A(u)$ – stupeň príslušnosti $\in [0;1]$,
všeobecne funkcia príslušnosti (FP)



Konvenčná (Cantorovská) množina (KM)
 $(\mu_A(u) \in \{0;1\})$ je špeciálny prípad FM.
 Všetko platné v konvenčnej teórii množín platí aj u FM.
 FM sú jedným z možných zovšeobecnení KM.
 (Možné sú aj iné zovšeobecnenia.)

FM je možné vzájomne porovnávať.

Fuzzy podmnožina



Charakteristiky FP

1. **Nosič A** (*support*) - množina $supp A$:

$$suppA = \{x \in X, \mu_A(x) > 0\}$$

2. **α -rez A** (*cut*) - množina A_α :

$$A_\alpha = \{x \in X, \mu_A(x) \geq \alpha\}$$

α -rez je striktný, ak pre všetky $x \in A_\alpha$ je $\mu_A(x) > \alpha$.

3. **α -hladina A** (*level*) - množina A^α :


$$A^\alpha = \{x \in X, \mu_A(x) = \alpha\}$$

4. **Jadro A** (*kernel*) - množina $KerA$:

$$KerA = \{x \in X, \mu_A(x) = 1\}$$

5. **Vrchol A** (*peak*) - prvok univerza $x = P(A)$ jadra A : ak jadro je jednoprvkovou množinou

6. **Výška A** (*height*) - $hgt(A)$: maximálna hodnota stupňa príslušnosti fuzzy množiny A



$Supp\ A = striktný\ A_0, Ker\ A = A_1$




$Ker\ A \subseteq A_\alpha \subseteq Supp\ A$

7. **Konvexnosť** - fuzzy množina A je konvexná práve vtedy, ak pre každé dva prvky $x, y \in X$ a každé číslo $\tau \in [0; 1]$ platí:

$$\mu_A(\tau x + (1 - \tau)y) \geq \min\{\mu_A(x), \mu_A(y)\}$$

Pozn.: Úloha sa transformuje na hľadanie minima.



Príklad nekonvexnej funkcie príslušnosti.

Spôsoby zápisu FM

1. Ak univerzum je v diskrétnom tvare, t.j. $X = \{x_1, x_2, \dots, x_n\}$:



- (a) $A = \{(x_1, \mu_A(x_1)), (x_2, \mu_A(x_2)), \dots, (x_n, \mu_A(x_n))\}$
- (b) $A = \{\mu_A(x_1)/x_1, \mu_A(x_2)/x_2, \dots, \mu_A(x_n)/x_n\}$
- (c) $A = \{\mu_A(x_1)/x_1 + \mu_A(x_2)/x_2 + \dots + \mu_A(x_n)/x_n\}$
- (d) $A = \sum_{i=1}^n \mu_A(x_i)/x_i$
- (e) Graficky pomocou diskrétnej funkcie príslušnosti $\mu_A(x_i) \quad \forall x_i \in X \quad i = 1, \dots, n$
- (f) Tabuľkou

2. Ak univerzum je v spojiteľnom tvare:

- (a) $A = \int_X \mu_A(x)/x \, dx$
- (b) Graficky pomocou spojitej funkcie príslušnosti $\mu_A(x), \quad \forall x \in X$

Základné typy FP





- Nelineárne FP S^+ , S^- , Π (zvonovitá):



$$F(x, a_1, b_1, c_1, a_2, b_2, c_2) = \begin{cases} 0 & x < a_1 \text{ alebo } x > a_2 \\ 1 & c_1 \leq x \leq c_2 \\ \frac{1}{2} \left(\frac{x-a_1}{b_1-a_1} \right)^2 & a_1 \leq x < b_1 \\ 1 - \frac{1}{2} \left(\frac{x-c_1}{c_1-b_1} \right)^2 & b_1 \leq x < c_1 \\ 1 - \frac{1}{2} \left(\frac{x-c_2}{b_2-c_2} \right)^2 & c_2 < x \leq b_2 \\ \frac{1}{2} \left(\frac{x-a_2}{a_2-b_2} \right)^2 & b_2 < x \leq a_2 \end{cases}$$

- Lineárne FP Z⁺, Z⁻, trojuholníková, lichobežníková:

$$F(x, x_1, x_2, x_3, x_4, k, b, c) = \begin{cases} 0 & x \in [0, x_1) \\ \left(\frac{k-b}{x_2-x_1} \right) \cdot (x - x_1) + b & x \in [x_1, x_2) \\ k & x \in [x_2, x_3) \\ \left(\frac{k-c}{x_3-x_4} \right) \cdot (x - x_4) + c & x \in [x_3, x_4] \\ 0 & x \in (x_4, +\infty) \end{cases}$$





Spôsoby získavania FP

- Manuálne – najčastejšie, potreba experta.
- Štatistické vyhodnotenie – dotazníky, transformácia dát.
- Fyzikálne merania – veľmi zriedkavé, problém ako „zmerať“ FP.
- Použitie prostriedkov UI – neurónové siete, genetické algoritmy, iné metódy učenia.

Lingvistická (jazyková) premenná (LP)

Je možné zoradiť FM ako čísla?





Definícia LP:

LP je usporiadaná pätnica $(\Gamma, T(\Gamma), X, G, M)$, kde:

Γ – **názov** lingvistickej premennej

$T(\Gamma)$ (T) – **term-množina**, t.j. množina všetkých *názvov lingvistických hodnôt premennej* (NHLP) Γ

X – **univerzum**

G – **syntaktické pravidlo** (bezkontextová gramatika), je zostavený NHLP Γ (prvok T)


M – **semantické pravidlo**, priraduje každej NHLP jej význam, t.j. jej funkciu príslušnosti

Fuzzy systémy


Operácie s fuzzy množinami
&
Štruktúra fuzzy regulátora

Operácie s FM

U konvenčných množín:



Priek




Zjednotenie

U fuzzy množín:



T-norma

T-konorma



$$a = \mu_A(u_1), c = \mu_A(u_2)$$

$$b = \mu_B(u_1), d = \mu_B(u_2)$$



T-norma: $[0, 1] \times [0, 1] \rightarrow [0, 1]$

$$(1:) \quad T(a, b) = T(b, a)$$

$$(2:) \quad T(T(a, b), e) = T(a, T(b, e))$$

$$(3:) \quad \forall a \leq c \text{ & } \forall b \leq d \Rightarrow T(a, b) \leq T(c, d)$$

$$(4:) \quad T(a, 1) = a$$

$$(5:) \quad T(a, 0) = 0$$

- Komutatívnosť
- Asociatívnosť
- Monotónne stúpajúca
- Identita
(neutrálny prvok)
- Nulový prvok

T-konorma: $[0, 1] \times [0, 1] \rightarrow [0, 1]$

$$(1:) \quad S(a, b) = S(b, a)$$

$$(2:) \quad S(S(a, b), e) = S(a, S(b, e))$$

$$(3:) \quad \forall a \leq c \text{ & } \forall b \leq d \Rightarrow S(a, b) \leq S(c, d)$$

$$(4:) \quad S(a, 0) = a$$

$$(5:) \quad S(a, 1) = 1$$

- Komutatívnosť
- Asociatívnosť
- Monotónne stúpajúca
- Identita
(neutrálny prvok)
- Jednotkový prvok


Doplnok: $[0, 1] \rightarrow [0, 1]$

$$(1:) \quad C(0) = 1 \quad \& \quad C(1) = 0$$

$$(2:) \quad \forall a < b \Rightarrow C(a) > C(b)$$

$$(3:) \quad C(C(a)) = a$$

- Ohraničenie
- Monotónne klesajúca
- Involúcia



Typy T-noriem & T-konoriem

1. Konjugované:

$$T(a, b) = 1 - S((1 - a), (1 - b))$$

a. Drastický súčin & súčet:

$$T_D(a, b) = \begin{cases} \min(a, b) & \text{Ak } \max(a, b) = 1 \\ 0 & \text{In} \end{cases}$$

$$S_D(a, b) = \begin{cases} \max(a, b) & \text{Ak } \min(a, b) = 0 \\ 1 & \text{In} \end{cases}$$

b. Ohraničený rozdiel & súčet (Lukasiewicz):

$$T_L(a, b) = \max(0, a + b - 1)$$

$$S_L(a, b) = \min(1, a + b)$$

c. Einsteinov súčin & súčet:

$$T_E(a, b) = \frac{a.b}{2 - (a + b - a.b)}$$

$$S_E(a, b) = \frac{a + b}{1 + a.b}$$

d. Algebraický (Larsenov) súčin & pravdepodobnostný súčet:

$$T_A(a, b) = a.b$$

$$S_A(a, b) = a + b - a.b$$

e. Hamacherov súčin & súčet:

$$T_{HC}(a, b) = \frac{a.b}{a + b - a.b}$$

$$S_{HC}(a, b) = \frac{a + b - 2.a.b}{1 - a.b}$$


f. Minimum & maximum:


$$T_M(a, b) = \min(a, b)$$


$$S_M(a, b) = \max(a, b)$$

Prísnosť (tolerancia) operátorov

Sietový graf







$$T_D \leq T_L \leq T_E \leq T_A \leq T_{HC} \leq T_M$$

$$S_M \leq S_{HC} \leq S_A \leq S_E \leq S_L \leq S_D$$

2. Parametrické operátory:

a. Hamacherov prienik & zjednotenie:

$$T_{HP}(a, b) = \frac{a.b}{\gamma + (1 - \gamma).(a + b - a.b)} \quad \gamma \geq 0$$

$$S_{HP}(a, b) = \frac{(\gamma - 1).a.b + a + b}{1 + \gamma.a.b} \quad \gamma \geq -1$$

b. Yagerov prienik & zjednotenie :

$$T_Y(a, b) = 1 - \min(1, ((1 - a)^\gamma + (1 - b)^\gamma)^{1/\gamma}) \quad \gamma \geq 1$$

$$S_Y(a, b) = \min(1, (a^\gamma + b^\gamma)^{1/\gamma}) \quad \gamma \geq 1$$

c. Min – Max kombinácia:

$$OP_{Min-Max}(a, b) = \gamma \cdot \min(a, b) + (1 - \gamma) \cdot \max(a, b)$$

$$\gamma \in [0; 1]$$

3. Spriemerňujúce operátory:


a. Fuzzy-AND:

$$OP_{AND}(a, b) = \gamma \cdot \min(a, b) + \frac{(1 - \gamma)(a + b)}{2}$$
$$\gamma \in [0; 1]$$

b. Fuzzy-OR:

$$OP_{OR}(a, b) = \gamma \cdot \max(a, b) + \frac{(1 - \gamma)(a + b)}{2}$$
$$\gamma \in [0; 1]$$

Štruktúra expertného systému (ES)



BZ & BD sú prísne oddelené.

BZ – Stála (nemenná) časť informácií

BD – Aktuálna (premenlivá) časť informácií

Fuzzy regulátor (FR) (*fuzzy controller*)

FR ako špeciálny ES schopný:


- pracovať ako nelineárny systém,
- byť robustným (premenlivosť parametrov),
- spracovať čiastočne protirečivé dátá a znalosti,
- plne nahradiť človeka z rozhodovania,
- pracovať v reálnom čase,
- udržiavať informáciu v podobe pravidiel (*user-friendly*).

Štruktúra FR



w^* – požadovaná hodnota
 y^* – skutočný výstup
 e^* – odchýlka (*error*), $e=w-y$
 u^* – akčný zásah

E.H. Mamdani
1974



Znalosti ako fuzzy produkčné pravidlá:

(k:) AK x_1 je LX_1^k & ... & x_n je LX_n^k POTOM u je LU^k



Predpoklad (premisa)

Dôsledok

LX_i^j – lingvistická hodnota (LH) (malý, starý, ...)

Väčšinou 7 LH v rámci jednej LP:

Z – zero – nulová

S – small – malá

M – medium – stredná

B – big – velká

P – kladná (positive), N – záporná (negative)

Prehľadová (*look-up*) tabuľka:

$\Delta e = PS$

$e = NM$

| $e/\Delta e$ | NB | NM | NS | Z | PS | PM | PB |
|--------------|----|----|----|----|----|----|----|
| NB | NB | NB | NB | NB | NM | NS | Z |
| NM | NB | | NB | | NS | Z | PS |
| NS | NB | | NM | | Z | PS | PM |
| Z | NB | NM | NS | Z | PS | PM | PB |
| PS | NM | NS | Z | PS | PM | | PB |
| PM | NS | Z | PS | PM | | PB | PB |
| PB | Z | PS | PM | PB | PB | PB | PB |

$u = NS$

AK e je NM & Δe je PS POTOM u je NS

Príklad – dodržiavanie bezpečného odstupu

Analýza vstupov & výstupov:


- vzdialenosť medzi autami (d)

Vstupy:

- rýchlosť približovania sa áut (v)


Výstupy:


- sila pre zrýchlenie / brzdenie (s)




Báza pravidiel:

| | | |
|---|---------------------------|------------------------------------|
| AK v je malá | & d je malá | POTOM s je nulová. |
| AK v je malá | & d je stredná | POTOM s je kladne stredná. |
| AK v je malá | & d je veľká | POTOM s je kladne veľká. |
| AK v je stredná & d je malá | | POTOM s je záporne stredná. |
| AK v je stredná & d je stredná | | POTOM s je nulová. |
| AK v je stredná & d je veľká | | POTOM s je kladne stredná. |
| AK v je veľká & d je malá | | POTOM s je záporne veľká. |
| AK v je veľká & d je stredná | | POTOM s je záporne stredná. |
| AK v je veľká & d je veľká | | POTOM s je nulová. |







Fuzzy systémy

Výpočtový cyklus fuzzy regulátora


&

Analýza bázy pravidiel


Fuzzifikácia

Transformácia: ostré číslo \rightarrow FM:


- singletonová: $LX_i = \{(x_i^*, \mu_{LX_i}(x_i^*))\}$
- tolerančná: $x_i^* = P(LX_i)$
 $supp\ LX_i = \text{tolerancia}$




Postup vyhodnocovania fuzzy pravidiel




- I. Výpočet kompatibility T_C
- II. Agregácia vstupov $T_A \rightarrow$ **sila pravidla** $\alpha \in [0; 1]$
- III. Vlastná inferencia $T_I \rightarrow C' \neq C$ ($C' \subseteq C$)
(C' – orezaná FP, (*clipped*))
- IV. Váhovanie $w_i \cdot C'$ – miera hodnotnosti pravidla
($w \in [0; 1]$)






&




OR



&



V. Akumulácia S_A



Defuzzifikácia

Transformácia: FM → ostré číslo:

- metódy ťažiska
- metódy maxima


1. Ťažisko (*Center of Gravity, Center of Area*):

$$u^* = \frac{\int_U u \cdot \mu_{LU_c}(u) du}{\int_U \mu_{LU_c}(u) du}$$

2. Súčtové ťažisko (*Center of Sums*):

$$u^* = \frac{\int_U u \cdot \sum_{k=1}^m \mu_{LU_c^k}(u) du}{\int_U \sum_{k=1}^m \mu_{LU_c^k}(u) du}$$

3. Čažisko najväčšieho priestoru:



4. Bisektorová metóda:

$$\int_a^{u^*} \mu_{LU_c}(u) du = \int_b^{u^*} \mu_{LU_c}(u) du$$

5. Metóda výšok (*Height method, Local Mean of Maxima*):

$$u^* = \frac{\sum_{k=1}^m p_k \cdot \alpha_k}{\sum_{k=1}^m \alpha_k}$$

6. Prvé, posledné, stredné maximum (*First, Last, Middle of Maxima, Global Mean of Maxima*), $u^*_{\min}, u^*_{\max}, u^*$:

$$u^* = u^*_{\min} + \frac{u^*_{\max} - u^*_{\min}}{2}$$

Metódy typu *fuzzy mean*:

$$u^* = \frac{\sum_{k=1}^m b_k \cdot \alpha_k}{\sum_{k=1}^m \alpha_k}$$

b_k – číslo charakterizujúce orezanú FP

m – počet odpálených pravidiel

Súčtové ťažisko, metóda výšok, ...

Kritériá hodnotenia defuzzifikačných metód

1. Spojitosť (*Continuity*)
2. Jednoznačnosť (*Unambiguity*)
3. Prijateľnosť (*Plausibility*)
4. Výpočtová náročnosť
5. Zohľadňovanie prekrytí (*Weight Counting*)

Niektoré kritériá sú jednoznačné – ostré (O)
a niektoré sú nejednoznačné – fuzzy (F).

Spojitosť: F


„Malej“ zmene vstupu ε má prislúchať „malá“ zmena výstupu δ :

$$\forall \varepsilon > 0 \exists \delta > 0 : |x(t+1)^* - x(t)^*| < \varepsilon \rightarrow |u(t+1)^* - u(t)^*| < \delta$$

Predpoklad: Existencia spojitej bázy pravidiel.

Jednoznačnosť: O

Ak vždy vie vypočítať práve jednu ostrú hodnotu u^* .



Prijateľnosť: F

Prijateľné riešenie $u^* \in LU$ by malo ležať „približne“ v strede nosiča $\text{Supp } LU$ a malo by mať „vysoký“ stupeň príslušnosti v LU .

Predpoklad: Existencia konvexnej FP.

Pozn.: Najlepšie vyhovujú metódy ťažiska.


Výpočtová náročnosť: F

Pozn.: Najrýchlejšie metódy maxima.

Zohľadňovanie prekrytí: O

Metódy, kde akumulácia nie je samostatným výpočtovým krokom (nestráca sa informácia o prekrytí FM).

$$LU = S_A(LU_c^1; LU_c^2)$$




Porovnanie defuzzifikačných metód

| Kritérium | Typ defuzzifikačnej metódy | | | | | |
|---------------------|----------------------------|------|-------|------|------|------|
| | 1. | 4. | 2. | 3. | 5. | 6. |
| Spojitosť | áno | áno | nie | áno | nie | nie |
| Jednoznačnosť | áno | áno | nie | áno | áno | áno |
| Prijateľnosť | áno | áno | áno | áno | nie | áno |
| Výpočtová zložitosť | veľká | malá | veľká | malá | malá | malá |
| Prekrytie | nie | áno | nie | áno | nie | nie |

Typy fuzzy regulátorov

- **Mamdaniho (1974)**
 - fuzzy P, PI, PD, PID
 - fuzzy kĺzavá regulácia
- **TSK**
 - Tsukamotov
- **Adaptívny FR**
 - samoladiteľný (samonastaviteľný)
 - samoučiaci sa (samoorganizačný)
- **Špeciálne návrhy**

Tsukamotov FR



Takagi – Sugeno – Kangov (TSK) FR

T. Takagi - 1985

Dôvod: Často problém spočíva v presnom popise daného stavu sústavy. Ak tento je ale známy, nie je taký problém v určení presného akčného zásahu



(k:) Ak x_1 je LX_1^k & ... & x_n je LX_n^k Potom $u_k^* = f_k(x_1^*, \dots, x_n^*)$

Pozn.: Tsukamotov FR je špeciálny prípad TSK FR.

Výpočtové fázy:

1. Fuzzifikácia: singletonová
2. Kompatibilita: priame dosadenie do FP
3. Agregácia: ľubovoľná T-norma (T-conorma)
4. Vlastná inferencia & akumulácia:

$$u^* = \frac{\sum_{k=1}^m \alpha_k \cdot u_k^*}{\sum_{k=1}^m \alpha_k}$$

m – počet odpálených pravidiel
 α_k – sila k-teho pravidla

5. Defuzzifikácia: –

Mamdani versus TSK FR

1. Mamdani: singletonová fuzzifikácia
2. Mamdani: defuzzifikácia typu fuzzy mean
3. TSK: $u_k^* = \text{defuzz}_{\text{Mamdani}}(L_{U_c^k})$




Mamdaniho FR = TSK FR

Pozn.: Mamdaniho FR sa použije vtedy, ak nie je možné použiť TSK FR, ktorý je výpočtovo jednoduchší a spravidla vie lepšie approximovať danú funkciu.

Mamdani FR → TSK FR

1. LU^k defuzzifikovať podľa ľažiska u_g^k a maxima u_m^k
2. Počiatočné $u_{TSK}^{kp} = (u_g^k + u_m^k)/2$
3. Výsledné u_{TSK}^{kv} bude väčšinou v okolí počiatočného u_{TSK}^{kp} .



Analýza bázy pravidiel (BP) FR

Diagram illustrating the analysis of the rule base (BP) for the Fuzzy Rule (FR) system.

The diagram shows the membership functions (MFs) for the input variable e and the output variable Δe .

Input Variable (e):

- NB (Negative Big)
- NM (Negative Medium)
- NS (Negative Small)
- Z (Zero)
- PS (Positive Small)
- PM (Positive Medium)
- PB (Positive Big)

Output Variable (Δe):


- 0
- 1
- 2
- 3
- 4

Rule Base Matrix:

| e | NB | NM | NS | Z | PS | PM | PB |
|-----|----|----|----|----|----|----|----|
| NB | NB | NB | NB | NB | NM | NS | Z |
| NM | NB | NB | NB | NM | NS | Z | PS |
| NS | NB | NB | NM | NS | Z | PS | PM |
| Z | NB | NM | NS | Z | PS | PM | PB |
| PS | NM | NS | Z | PS | PM | PB | PB |
| PM | NS | Z | PS | PM | PB | PB | PB |
| PB | Z | PS | PM | PB | PB | PB | PB |

Color Coding:

- Yellow Cells:** NB, NM, PS, PM, PB (Rows 1-5)
- Red Cells:** NS, Z (Rows 3-4)
- Green Cells:** NS, Z, PS, PM (Rows 6-7)



Kritériá hodnotenia bázy pravidiel

1. Úplnosť (completeness)
2. Konzistentnosť, neprotirečivosť (consistency)
3. Spojitosť (continuity)

Úplnosť


Báza pravidiel je úplná, ak ľubovoľná kombinácia vstupných hodnôt vedie k nepráznej fuzzy množine výstupu:

$$\forall x_1, \dots, x_n : \text{hgt}(\text{LU}_C(x_1, \dots, x_n)) > 0$$

Pozn.:

- V regulačnej ploche sa nesmú nachádzať nedefin. „diery“.
- Takmer žiadna aplikačná BP nie je úplná.
- Úplnosť BP nesúvisí s existenciou nedefinovaných pravidiel.

Príklad úplnej BP



Konzistentnosť

Prísna definícia:

BP je nekonzistentná, ak existujú aspoň dve pravidlá s rovnakým predpokladom, ale rôznym dôsledkom.

Menej prísna definícia:

BP je nekonzistentná, ak existujú aspoň dve pravidlá s rovnakým predpokladom a prienik ich dôsledkov je prázdna množina.



Pozn.:

- Menej prísna definícia pripúšťa istú mieru protirečivosti.
- Protirečivosť je charakteristickým rysom zložitých systémov, preto vyšetrovanie konzistentnosti nehrá tak dôležitú úlohu.
- Protirečivé pravidlá nie je možné použiť, ak reprezentácia pravidiel je v maticovom tvare (prehľadová tabuľka).

Spojitosť

BP je spojité, ak neexistujú žiadne susedné pravidlá, výstupy ktorých majú prázdny prienik.

| | | | | |
|----|----|----|----|----|
| NS | | | PS | NS |
| | | Z | PB | Z |
| | NS | Z | NS | |
| PB | PS | PS | NB | |
| PB | PB | NB | NB | |

Porušenie spojitosťi

Pozn.:

- Prázdne pravidlo sa do susednosti nepočíta.
- Úplnosť a spojitosť BP nie sú navzájom závislé. Úplná BP nemusí byť ešte spojité. Spojitá BP nemusí byť úplná.
- Porušenie spojitosti BP môže mať vážne následky na robustnosť systému a jeho spoľahlivosť.

Fuzzy systémy

Vplyv parametrov na činnosť fuzzy
regulátora

&

Úvod do adaptívnych fuzzy regulátorov


Vplyvy parametrov FR na jeho činnosť

Typy parametrov:

- Funkcie príslušnosti
- Pravidlá
- Inferenčné parametre:
 - operátory (T_C , T_A , T_I)
 - normalizačné a denormalizačné koeficienty
 - fuzzifikačná a defuzzifikačná metóda

Všeobecné poznámky

- Jednotná reprezentácia FP (jednoduchosť výpočtu)
- Nelineárne priebehy zodpovedajú viac realite, ale sú výpočtovo náročné.
- Lichobežníkové FP sú v oblasti jadra necitlivé.
- Linearizované FP v bodoch zlomov nie sú derivovateľné, t.j. vzniká riziko nestabilít.
- Odporuča sa zachovávať fuzzy partície a FP majú byť normálne.
- FP výstupov by mali byť symetrické (možnosť využitia aj maximovej defuzzifikácie).




Normálna FP - $\mu(x_p) = 1$

Symetrická FP - $w_l=w_r$ (width - šírka)


Úroveň pretnutia - cpl (Cross-Point Level)

- cpl má byť > 0 (kvôli zamedzeniu ne definovaných častí na univerze), väčšinou $\langle 0,5; 0,7 \rangle$.
- Pre lineárne systémy do 3. rádu, symetrické FP a $cpl=0,5$ bude odozva s malým prekmitom, rýchlejším prechodom a malým podkmitom. Tvar FP nemá vplyv, iba lichobežníkové FP spomalia prechodový dej.




- Interval hodnôt (nosič), na ktorom sú definované FP, musí byť široký aspoň $4.\sigma$ (σ - variancia), ak sa predpokladá Gaußovský priebeh vzniku šumu (aby hodnota zostala na definičnom obore FP).
- Počet úrovní kvantovania FP (počet uvažovaných stupňov príslušnosti) vplýva na prekmity, tlmenie a vznik oscilácií.
- Veľké prekrývanie FP spôsobuje zložitý tvar aproximačnej plochy, kde navzájom vplývajú aj vzdialené body. Plocha sa „vyhľadzuje“. Zmena dôsledkov v pravidlách nie je triviálna.
- Ak sa navzájom prekrývajú práve 2 konvexné a normálne FP, kde platí fuzzy partícia, potom aproximácia závisí iba na najbližších charakteristických bodoch.
- Čím je vyšší počet FP, tým je zložitejší výstup.

- Častokrát je voľba ostrých dôsledkov v podobe konštant dostatočná.
- Výhodné použitie lineárneho rozdelenia FP pre výstup.
- Výhodné použitie logaritmického rozdelenia FP pre vstup.



Lineárne rozdelenie




Logaritmické rozdelenie

Fuzzy partícia: $\forall x \in X \mid \sum_{i=1}^n \mu_i(x) = 1$

Analýza regulačnej plochy

Pozn.: Regulačná plocha = funkcia FR.



Saturácia akčného zásahu

Možnosť rozkmitu (veľké nelinearity)

Riziko narušenia robustnosti

Adaptívne FR


Priama (čistá) fuzzy adaptácia:

- Inkrementálne modely (Jacobian)
- Gradientové metódy
- Štatistické metódy
- Interpolačné prístupy
- Symbolické výpočty
- Genetické algoritmy (väčšinou)

Nepriama fuzzy adaptácia:

- Neurónové siete (neuro-fuzzy: RBF, Anfis, Falcon)
- Genetické algoritmy (čiastočne)

Priama fuzzy adaptácia



Pozn.:

Adaptívny = schopnosť prispôsobovať sa, t.j. samoladenie & samoučenie.


Požiadavky na činnosť:

1. Schopnosť aspoň čiastočne získavať znalosti.
2. Prispôsobivosť na meniace sa podmienky procesu.
3. Perspektívne plne automatizovaný proces učenia sa bázy znalostí (BZ).


Typy AFR podľa monitora procesu:

1. Výkonnostné AFR (performance AFC) - na základe miery splnenia kritéria kvality adaptuje BZ.
2. Parametrické AFR (parameter AFC) - adaptuje BZ na základe identifikácie modelu sústavy.

Typy AFR podľa modifikovaných častí BZ:



Procyk-Mamdaniho samoorganizačný fuzzy regulátor (PMSFR) (PM-AFR)



Sústava:

$$y = M(u)$$

$$g(y) \approx M^{-1}(y)$$

Regulátor:

$$u = g(y)$$

$$p = M = T \cdot J \cdot r$$

T - períoda vzorkovania

J - Jacobian

(determinant matice dynamiky)

p - miera výkonnosti

r - opravná (reinforcement) hodnota


$$J = \begin{vmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{vmatrix}$$

$$\bar{f} = \frac{d \bar{X}(t)}{dt} = \bar{F}(t) \cdot \bar{X}(t) + \bar{B}(t) \cdot u(t)$$

$$J(t) = |F(t)|$$

Adaptačné pravidlo

$$R(k+1) = (R(k) \cap \overline{R_{zľá}}(k)) \cup R_{nová}(k)$$



$$R_{zľá}(k) = fuzz(x_1^*(k)) \times \dots \times fuzz(x_n^*(k)) \times fuzz(u^*(k))$$

$$R_{nová}(k) = fuzz(x_1^*(k)) \times \dots \times fuzz(x_n^*(k)) \times fuzz(u^*(k) + r(k))$$

Gradientové prístupy

Ciel':

Minimalizovať chybu (regulačnú odchýlku)

$$E = \frac{1}{2}(w - y)^2$$

w – žiadana (očakávaná) hodnota

y – skutočný výstup


$$\left(-\frac{\partial E}{\partial p_1}, -\frac{\partial E}{\partial p_2}, \dots, -\frac{\partial E}{\partial p_n}\right)$$

p_i – parameter bázy znalostí (*napr. vrchol, šírka nosiča FP*)

$$p_i(k+1) = p_i(k) + \gamma \frac{\partial E}{\partial p_i}$$

γ – parameter učenia

(k:) Ak $x_1 \in L X_1^k \& \dots \& x_n \in L X_n^k$ Potom $u_k^* = f_k(x_1^*, \dots, x_n^*)$



$$n = 2.pv.pp + pp$$


*p*v – počet vstupov

pp – počet pravidiel

$$\Delta a_{i,j} = 2.(w - y).\operatorname{sgn}(x_i - a_{i,j}) \cdot \frac{\left(\sum_{p=1}^{N_{A_{i,j}}} \alpha_p \cdot b_p - y \cdot \sum_{p=1}^{N_{A_{i,j}}} \alpha_p \right)}{\sum_{p=1}^{N_r} \alpha_p \cdot s_{i,j} \cdot \mu_{A_{i,j}}(x_i)}$$

$$\Delta s_{i,j} = (w - y).(1 - \mu_{A_{i,p}}(x_i)) \cdot \frac{\left(\sum_{p=1}^{N_{A_{i,j}}} \alpha_p \cdot b_p - y \cdot \sum_{p=1}^{N_{A_{i,j}}} \alpha_p \right)}{\sum_{p=1}^{N_r} \alpha_p \cdot s_{i,j} \cdot \mu_{A_{i,j}}(x_i)}$$

$$\Delta b_j = \frac{\sum_{p=1}^{N_{b_j}} \alpha_p \cdot (w - y)}{\sum_{p=1}^{N_r} \alpha_p}$$



$$\Delta a_{i,j} = \begin{cases} \frac{y-w}{a_{i,j}-a_{i,j-1}} \cdot \left[\frac{\mu_{A_{i,j}}(x_i)}{\mu_{A_{i,j-1}}(x_i)} \cdot \sum_{p=1}^{N_{A_{i,j-1}}} \alpha_p \cdot (b_p - y) - \sum_{p=1}^{N_{A_{i,j}}} \alpha_p \cdot (b_p - y) \right]; \\ \quad \text{if } a_{i,j-1} < x_i < a_{i,j} \\ \frac{y-w}{a_{i,j}-a_{i,j+1}} \cdot \left[\frac{\mu_{A_{i,j}}(x_i)}{\mu_{A_{i,j+1}}(x_i)} \cdot \sum_{p=1}^{N_{A_{i,j+1}}} \alpha_p \cdot (b_p - y) - \sum_{p=1}^{N_{A_{i,j}}} \alpha_p \cdot (b_p - y) \right]; \\ \quad \text{if } a_{i,j} < x_i < a_{i,j+1} \\ 0; \quad \text{otherwise} \end{cases}$$

$$\Delta b_r = \alpha_r \cdot (y - w)$$


Fuzzy systémy

Fuzzy relácie

&

Dokončenie PM-AFR

Fuzzy relácie



$$\mathfrak{R} = \int_{XxY} \mu_{\mathfrak{R}}(x, y) / (x, y) \text{ resp. } \mathfrak{R} = \sum_{XxY} \mu_{\mathfrak{R}}(x, y) / (x, y)$$

Príklady fuzzy relácií

$\mathcal{S} = \text{,,}x \text{ približne rovné } y\text{,,}$

$\mathcal{S} \subseteq X \times Y$

| | 1 | 2 | 3 | 4 |
|---|----|----|----|----|
| 1 | 1 | .8 | .3 | 0 |
| 2 | .8 | 1 | .8 | .3 |
| 3 | .3 | .8 | 1 | .8 |


X

$\mathcal{R} = \text{,,}x \text{ značne väčšie než } y\text{,,}$

$\mathcal{R} \subseteq X \times Y$

| | y_1 | y_2 | y_3 | y_4 |
|-------|-------|-------|-------|-------|
| x_1 | .8 | 1 | .1 | .7 |
| x_2 | 0 | 1 | 0 | 0 |
| x_3 | .9 | 1 | .7 | .8 |

Sagitálny diagram



| | | | | | |
|-----------------|-------|------|------|------|------|
| | x_1 | $.8$ | 1 | $.1$ | $.7$ |
| $\mathcal{R} =$ | x_2 | 0 | $.8$ | 0 | 0 |
| | x_3 | $.9$ | 1 | $.7$ | $.8$ |

Prepis produkčného pravidla do fuzzy relácie

(k:) Ak x_1 je $LX_1^k \ \& \dots \ \& x_n$ je LX_n^k Potom u je LU^k




$$\mathcal{R}_k = \int_{X_1 \times \dots \times X_n \times U} T_I(\mu_{LX_1^k}(x_1), \dots, \mu_{LX_n^k}(x_n), \mu_{LU^k}(u)) / (x_1, \dots, x_n, u)$$

Ak je m pravidiel, t.j. \mathcal{R}_k ($k=1, \dots, m$), potom celková báza znalostí je v tvare:

$$\cup - \text{akumulácia} \quad \mathcal{R} = \bigcup_{k=1}^m \mathcal{R}_k = S_A(\mathcal{R}_1, \dots, \mathcal{R}_m)$$

Príklad: Ak e_θ je LE_θ & e_q je LE_q Potom u je $L\Delta_\eta$



$$\mathfrak{R} = \sum_{E_\theta \times E_q \times \Delta\eta} \mu_{\mathfrak{R}}(e_\theta, e_q, \Delta\eta) / (e_\theta, e_q, \Delta\eta)$$

Operácie s fuzzy reláciami

FM je špeciálny prípad unárnej fuzzy relácie.



Čo platí pre FM, to platí aj pre fuzzy relácie.

- Prienik (t-normy)
- Zjednotenie (t-conormy)
- Doplňok
- Projekcia
- Cylindrické rozšírenie
- Kompozícia

$$\mathcal{R} \cap \mathcal{S} =$$

$$X \quad (\cap\text{-}min)$$


| Y | | | | |
|-----|----|-----------|----|----|
| | .8 | .8 | .1 | 0 |
| | 0 | .8 | 0 | 0 |
| | .3 | .8 | .7 | .8 |

$$\mathcal{R} \cup \mathcal{S} =$$

$$X \quad (U\text{-}max)$$

| Y | | | | |
|-----|----|----------|----|----|
| | 1 | 1 | .3 | .7 |
| | .8 | 1 | .8 | .3 |
| | .9 | 1 | 1 | .8 |

Projekcia



Všeobecne:

$$\mathfrak{R} \subseteq \prod_{i=1}^n X_i$$

$(i_1, \dots, i_k) \subset (1, \dots, n)$ - zvyškové súradnice

$(j_1, \dots, j_l) \subset (1, \dots, n)$ - odstraňované súradnice

$$(i_1, \dots, i_k) \cap (j_1, \dots, j_l) = \{\emptyset\}$$

$$(i_1, \dots, i_k) \cup (j_1, \dots, j_l) = (1, \dots, n)$$

$$V = \prod_{m=i_1}^{i_k} X_m$$

$$\mathfrak{I} = \text{Proj} \mathfrak{R} \text{ na } V = \int_V \sup_{X_{j_1}, \dots, X_{j_l}} \mu_{\mathfrak{R}}(x_1, \dots, x_n) / (x_{i_1}, \dots, x_{i_k})$$

Cylindrické rozšírenie (Cylindrical Extension)

$$A = \begin{array}{c|c} x_1 & 1 \\ \hline x_2 & .8 \\ \hline x_3 & 1 \end{array} \quad \xrightarrow{\hspace{2cm}} \quad \text{ce}(A) = \begin{array}{c|c|c|c} x_1 & y_1 & y_2 & y_3 & y_4 \\ \hline x_2 & 1 & 1 & 1 & 1 \\ \hline x_3 & .8 & .8 & .8 & .8 \\ \hline \end{array}$$

Všeobecne:

$$\text{ce}(\mathfrak{I}) = \int_X \mu_{\mathfrak{I}}(x_{i1}, \dots, x_{ik}) / (x_1, \dots, x_n)$$

$\text{Proj}_{\mathcal{J}}(\mathcal{I}) \text{ na } V = \mathcal{I}$

$\text{ce}(\text{Proj } \mathcal{R} \text{ na } V) \neq \mathcal{R}$

Pozor:

**Hrany matice relácie môžu byť definované v
ľubovoľnom poradí, to však v d'alšom musí byť
dodržané !!!**

Kompozícia

$\mathfrak{R}: A \rightarrow B \subseteq X \times Y$ - známe

A - známe ($A \subseteq X$)

B - neznáme ($B \subseteq Y$)

$$B = A \circ \mathfrak{R} = \text{Proj}(\text{ce}(A) \cap \mathfrak{R}) \text{ na } Y$$

\cap - vlastná inferencia T_I

Pre n vstupov fuzzifikovaných X_1, \dots, X_n :


$$B = A \circ \mathfrak{R} = \text{Proj}(T_A(\text{ce}(X_1), \dots, \text{ce}(X_n)) \cap \mathfrak{R}) \text{ na } Y$$

$$B = A \circ \mathfrak{R} = \text{Proj}(T_I(T_A(\text{ce}(X_1), \dots, \text{ce}(X_n)), \mathfrak{R})) \text{ na } Y$$

Príklad na výpočet kompozície

1. Vilma je o niečo vyššia ako Tilda.
2. Nech odhad výšky Vilmy je:

$$\text{Vilma} = \{ 0/170 + .1/172,5 + .4/175 + .7/177,5 + \\ + .9/180 + 1/182,5 + 1/185 \}$$



$\mathcal{R} = „x \text{ niečo vyššia ako } y“$

| | | 170 | 172,5 | 175 | 177,5 | 180 | 182,5 | 185 |
|--------------|-------|-----|-------|-----|-------|-----|-------|-----|
| | | 170 | 172,5 | 175 | 177,5 | 180 | 182,5 | 185 |
| Vilma (x) | 177,5 | .7 | 1 | .7 | .4 | .1 | 0 | 0 |
| | 175 | 1 | .7 | .4 | .1 | 0 | 0 | 0 |
| 172,5 | .7 | .4 | .1 | 0 | 0 | 0 | 0 | 0 |
| 170 | .4 | .1 | 0 | 0 | 0 | 0 | 0 | 0 |

Tilda (y)

ce(Vilma)

| | | | | | | | |
|-------|----|----|----|----|----|----|----|
| 185 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 182,5 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 180 | .9 | .9 | .9 | .9 | .9 | .9 | .9 |
| 177,5 | .7 | .7 | .7 | .7 | .7 | .7 | .7 |
| 175 | .4 | .4 | .4 | .4 | .4 | .4 | .4 |
| 172,5 | .1 | .1 | .1 | .1 | .1 | .1 | .1 |
| 170 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |


$T_I(\text{ce(Vilma)}, R(x,y))$

($T_I - \text{min}$)

| | $T_I(\text{ce(Vilma}), R(x,y))$ | | | | | | |
|-------|---------------------------------|-------|-----|-------|-----|-------|-----|
| | 0 | .1 | .4 | .7 | 1 | .7 | .4 |
| 185 | 0 | .1 | .4 | .7 | 1 | .7 | .4 |
| 182,5 | .1 | .4 | .7 | 1 | .7 | .4 | .1 |
| 180 | .4 | .7 | .9 | .7 | .4 | .1 | 0 |
| 177,5 | .7 | .7 | .7 | .4 | .1 | 0 | 0 |
| 175 | .4 | .4 | .4 | .1 | 0 | 0 | 0 |
| 172,5 | .1 | .1 | .1 | 0 | 0 | 0 | 0 |
| 170 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| | 170 | 172,5 | 175 | 177,5 | 180 | 182,5 | 185 |

Tilda = Proj $T_I(\text{ce}(\text{Vilma}), R(x,y))$ na Y

$$\begin{aligned}\text{Tilda} = \{ & .7/170 + .7/172,5 + .9/175 + 1/177,5 + \\ & + 1/180 + .7/182,5 + .4/185 \}\end{aligned}$$



Formy reprezentácie znalosti vo fuzzy systémoch

1. Fuzzy produkčné pravidlá – inferencia podľa jednotlivých pravidiel (*najviac používané*)
2. **Fuzzy relácie** – kompozičná inferencia
3. *Fuzzy asociatívne pamäte (memories) - FAM*
4. *Fuzzy kognitívne mapy (asociatívne siete)*

⋮

Inferencia podľa jednotlivých pravidiel verzus kompozičná inferencia

1. Podľa jednotlivých pravidiel (*individual rule based*)
 - + reprezentácia znalostí v pravidlách (user-friendly)
 - + nižšia výpočtová náročnosť
 - báza znalostí rozdelená na FP a pravidlá
 - vysoký počet parametrov bázy znalostí
2. Kompozičná (*compositional based inference*)
 - + jednoduchý princíp inferencie
 - výpočtovo náročná
 - strata pravidlovej reprezentácie znalostí

Adaptácia PM-AFR - dokončenie

Pravidlový prístup (produkčné pravidlá)

Nevýhody:


- Možnosť zmeniť naraz **iba jedno** pravidlo
- Ktoré pravidlo adaptovať?
- Nárast počtu pravidiel
- Potreba „**zberu odpadkov**“ (garbage collection)

Relačný prístup (fuzzy relácie)

Nevýhody:

- Strata IF-THEN reprezentácie znalostí
- Vysoká výpočtová náročnosť

Nárast výpočtovej náročnosti u fuzzy relácií



Veľkosť matice závisí od veľkosti diskretizácie
[4 x 5] = 20 [8 x 10] = 80 \rightarrow Riedke matice
(sparse matrix)

Nárast počtu pravidiel

$np(k)$ - počet pravidiel v čase k

n - počet vstupov do pravidla

$R_{zľá}(k)$ - $A_1^{zľá}(k) \times \dots \times A_n^{zľá}(k) \times B^{zľá}(k)$

$R_{nová}(k)$ - $A_1^{zľá}(k) \times \dots \times A_n^{zľá}(k) \times B^{nová}(k)$

$$R(k+1) = \left[\bigcup_{p=1}^{np} (A_{1,p} \cap \overline{A_1^{zľá}}) \times \dots \times A_{n,p} \times B_p \right] \cup \\ \dots \cup \left[\bigcup_{p=1}^{np} A_{1,p} \times \dots \times (A_{n,p} \cap \overline{A_n^{zľá}}) \times B_p \right] \cup \\ \bigcup \left[\bigcup_{p=1}^{np} A_{1,p} \times \dots \times A_{n,p} \times (B_p \cap \overline{B^{zľá}}) \right] \cup \\ \underbrace{\bigcup (A_1^{zľá} \times \dots \times A_n^{zľá} \times B^{nová})}_{R_{nová}}$$

Dôsledky:

- $np(k+1) = np(k) \cdot (n+1) + 1$
- Zmena tvarov FP, t.j. zmena významu lingvistických výrazov
- V každom kroku zmena iba 1 pravidla, t.j. dlhšia adaptácia
- Ktoré pravidlo meniť???




Riešenie:

Mechanizmus odpratávania odpadkov
(Garbage Collection)

Ciel:

- Zlúčiť podobné FP (mp - miera podobnosti)
- Vylúčenie identických pravidiel
- Vylúčenie pravidiel s malou výpovednou schopnosťou
(malé hodnoty stupňov príslušnosti FP)

$$mp = \frac{S(A \cap B)}{S(A \cup B)}$$



- $mp \in [0; 0,5)$ - pridať novú FP + nové pravidlo
- $mp \in [0,5; 0,8]$ - spriemerovať FP + škrtnúť identické pravidlá
- $mp \in (0,8; 1]$ - nová FP sa nepridá, nové pravidlo používa pôvodnú FP (ak ešte nie je)

Zjednodušená adaptácia

$$A_1^{zľá}(k) \times \dots \times A_n^{zľá}(k) \times \text{fuzz}(\text{defuzz}(B^{zľá}(k)) + r(k))$$


Fuzzy systémy

Fuzzy kognitívne mapy

Kognitívne mapy (KM)

Tolman – 1948, Axelrod - 1976


Pojmová mapa (PM):
(Conceptual Map)



C_i – symbolické pojmy


Väzby – vzťahy (rôznej povahy) medzi pojмami

Príklad PM: *Pojmová mapa o sebe samej*




Numerická interpretácia KM

Významy:





Hodnoty:
(aktivácie)




$\alpha = 1$ – pojem platí

$\alpha = 0$ – pojem neplatí

Príklad KM: Kognícia ovčiarskeho psa



KM & produkčné pravidlá



Ak C_1 Potom C_5
Ak C_5 Potom C_4
Ak C_4 Potom *nie* C_5
Ak C_4 Potom *nie* C_3
Ak C_3 Potom C_5
Ak C_1 Potom *nie* C_4
Ak C_1 Potom *nie* C_2
Ak C_2 Potom *nie* C_1
Ak C_2 Potom C_3

čas: (t) (t+1)

Pozn.: Produkčné pravidlá sú najjednoduchšie KM.

Oblasti využitia KM


- Biológia
 - skúmanie orientácie v priestore
 - skúmanie procesov učenia sa
 - tvorba mentálnych máp (krysy, líšky)
- Sociológia
 - proces vzdelávania (*učebná látka ako KM*)
 - modelovanie spoločenských procesov (*terorizmus*)
 - prostriedky skupinového rozhodovania
- Medicína – diagnostika (*duševné poruchy*)

Výhody KM

- Zachytenie reťazených väzieb (najmä *kauzálnych, možné aj časové*) medzi pojмami (nadstavba produkčných pravidiel)
- Prehľadnosť popisu (*user-friendly*)
- Možnosť postupnej tvorby modelu reálneho sveta a zlučovať čiastkové KM
- Schopnosť previesť implicitné znalosti do symbolickej podoby
- Možnosť modelovať javy a ich závislosti v diskrétnom čase

Nevýhody KM

- Iba kvalitatívne modely ($1 - \text{platí}$, $0 - \text{neplatí}$, $-1 - \text{negácia}$) → hrubý a nepresný popis
- Problém „nerozhodnosti“




Pôsobenie protichodných kauzálnych vplyvov

Prečo fuzzifikovať KM?


Príklad: Vývoj politickej situácie

Balder - 2004



Fuzzy kognitívne mapy (FKM)

Kosko - 1986



$$\text{FKM} = (\mathcal{C}, \mathcal{E}, \alpha, f)$$

\mathcal{C} – množina (symbolických) pojmov $\mathcal{C} = \{C_1, C_2, \dots, C_n\}$

\mathcal{E} – množina väzieb $\mathcal{E} = \{e_{11}, e_{12}, \dots, e_{nn}\}$, $e_{ij} \in [-1; 1]$

E – matica väzieb, resp. susednosti

α – množina hodnôt aktivácií pojmov C_i $\alpha = \{\alpha_1, \dots, \alpha_n\}$

$\alpha \in [-1; 1]$, resp. $[0; 1]$

f – obmedzovacia funkcia $R \rightarrow [-1; 1]$, resp. $[0; 1]$

Chovanie FKM: $\alpha(t+1) = f(\alpha(t).E)$

resp.

$$\alpha(t+1) = f(\alpha(t) + \alpha(t).E)$$

Typy obmedzovacích funkcií:


1. Prahová:

$$f(x) = \begin{cases} 1, & x > T \\ 0, & x \leq T \end{cases}, \quad f(x) = \begin{cases} 1, & x > T \\ 0, & x = T \\ -1, & x < T \end{cases}$$

T - prah

2. Sigmoidálna:

$$f(x) = \frac{1}{1 + e^{-\lambda x}}$$




3. Lineárne lomená:

$$f(x) = \begin{cases} 1, & x > k \\ \frac{x}{k}, & -k \leq x \leq k \\ -1, & x < -k \end{cases}$$

Analýza FKM

Nech v čase $t = 0$:



$$i \rightarrow j \quad j$$

$$E = \begin{bmatrix} 0 & -1 & 0 & -1 & 1 \\ -1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & 0 & -1 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$


i

$$\alpha(t+1) = f(\alpha(t).E)$$

$$\alpha(t) = [1 \ 0 \ -1 \ 0 \ 0]$$

$$\alpha(t+1) = [0 \ -1 \ 0 \ -1 \ 0]$$





PB – pevný bod


MC – medzný cyklus

CA – chaotický atraktor

Formy implementácie FKM

1. FKM ako hybridný systém jednoduchých fuzzy pravidiel
2. FKM ako „rekurentná NS“ ($\text{FKM} \neq \text{NS}$)
3. FKM ako konečný automat

FKM ako hybridný systém fuzzy pravidiel




$$B'_i = \alpha_i \cdot B_i = \text{Prod}(\alpha_i, B_i)$$

α_i – aktivácia pojmu A_i , t.j. sila pravidla

e_i – hodnota väzby, t.j. váha pravidla (w_i)


Postup manuálneho návrhu FKM


1. Expert nadefinuje charakteristické pojmy.
2. Expert určí väzby medzi pojmi (existencia, orientácia).
3. Expert ohodnotí váhy jednotlivých väzieb.




Fuzzy kognitívna mapa vyjadruje expertné znalosti o kauzálnych (funkčných) vzťahoch v modelovanom systéme - obsahuje teda znalosti o **dynamickom chovaní** systému

Príklad: Navigácia robota medzi prekážkami







POZÍCIA CIEĽA



ZATOČENIE



CIEĽ blízko



PREKÁŽKA



Fuzzy systémy

Implikácia & pravidlá usudzovania

Relácie podobnosti & 5 najbližších susedov

Hranové operátory

Systémy pravdivostných hodnôt

Multidimenzionálne uvažovanie

Problémy konvenčných FR

$AK \quad x \text{ je } A \text{ } \& \text{ } y \text{ je } B \quad POTOM \quad u \text{ je } C \quad :w_i$

1. Vlastná inferencia sa má vykonávať pomocou implikácie. T-norma nie je implikátor!
2. Problém agregácie – nie je možné vykonávať operácie medzi FM definovanými na rôznych univerzách → multidimenzionálne uvažovanie.

Vlastná inferencia

implikácia \subseteq vlastná inferencia

\Rightarrow

\rightarrow

| A | B | $A \Rightarrow B$ |
|----------|----------|-------------------------------------|
| 1 | 1 | 1 |
| 1 | 0 | 0 |
| 0 | 1 | 1 |
| 0 | 0 | 1 |

Typy vlastných inferencií

1. **S-implikácie** $A \Rightarrow B = \neg A \vee B \equiv S(C(A), B) = I_S(A, B)$

2. **QL-implikácie** (*Quantum Logic*)

$A \Rightarrow B = \neg A \vee (A \wedge B) \equiv S(C(A), T(A, B)) = I_{QL}(A, B)$

S, T - konjugované

3. **R-implikácie** (zovšeobecnený modus ponens)

$$I(A, B) = \begin{cases} 1, & \text{ak } A \leq B \\ 0, & \text{ak } A=1 \wedge B=0 \\ \in (0; 1) & \text{ináč} \end{cases}$$

$$I_R(A, B) = \sup \{ \gamma \in [0; 1] \mid I_V(A, \gamma) \leq B \}$$

4. **Konjukcie** $I_C(A, B) = T(A, B)$ - nie implikátor

Niektoré typy implikátorov

1. Kleene - Dienes

$$I_{KD}(A, B) = \max(1 - A, B)$$

2. Łukasiewiczov

$$I_L(A, B) = \min(1, 1 - A + B)$$

3. Zadehov

$$I_Z(A, B) = \max(\min(A, B), 1 - A)$$

4. Stochastický

$$I_S(A, B) = \min(1, 1 - A) + A \cdot B$$

5. Goguenov

$$I_{Gg} = \min(1, \frac{B}{A})$$

6. Gödelov

$$I_{Gd} = \begin{cases} 1, & \text{ak } A \leq B \\ B & \text{ináč} \end{cases}$$

7. Ostrý (špeciálny prípad I_{Gd})

$$I_O = \begin{cases} 1, & \text{ak } A \leq B \\ 0 & \text{ináč} \end{cases}$$

8. Všeobecný

$$I_V = \min(I_\alpha(A, B), I_\beta(1 - A, 1 - B))$$

$$\alpha, \beta - I_{Gd}, I_O$$

Modus ponens (pravidlo odlúčenia)

Vyjadruje princíp **kauzality** v produkčných pravidlach (príčina - dôsledok) a spôsob jeho odvodzovania.

Úloha:

Ak platí: Ak x je A Potom y je B
Ak platí aj: x je A

Potom platí: y je B dôsledok (neznámy)

$$((A \Rightarrow B) \wedge A) \Rightarrow B$$

Príklad:

Pravidlo: *Ak prší, potom je mokrá cesta.*

x: Prší.



y: Cesta je mokrá.

Problém: *Aká je cesta, ked' neprší? Mokrá alebo suchá?
(Čo ak ju polievali cestári?)*



Konvenčný modus ponens nevie zodpovedať otázku.

| A | $A \Rightarrow B$ | B |
|-----|-------------------|-----|
| 1 | 1 | 1 |
| 0 | 1 | ? |

Zovšeobecnený modus ponens

Ak platí: Ak x je A Potom y je B

Ak platí aj: x je $A' \neq A$

Potom platí: y je $B' \neq B$

Modus tollens (reductio ad absurdum)

Vyjadruje princíp **kauzality** v produkčných pravidlách (*dôsledok - príčina*) a spôsob jeho odvodzovania.

Úloha:

Ak platí: Ak x je A Potom y je B } dôsledok
Ak platí aj: y nie je B } (známy)

Potom platí: x nie je A predpoklad (neznámy)

$$((A \Rightarrow B) \wedge \neg B) \Rightarrow \neg A$$

Príklad:

Pravidlo: *Ak prší, potom je mokrá cesta.*

y: *Cesta nie je mokrá.*



x: *Neprší.*

Problém: *Aké je počasie, ked' cesta je mokrá?*

Prší alebo neprší?

(Čo ak ju polievali cestári?)



Konvenčný modus tollens nevie zodpovedať otázku.

| B | $A \Rightarrow B$ | A |
|-----|-------------------|-----|
| 1 | 1 | ? |
| 0 | 1 | 0 |

Zovšeobecnený modus tollens

Ak platí: Ak x je A Potom y je B
Ak platí aj: y je $B' \neq B$

Potom platí: x je $A' \neq A$


Relácie podobnosti (RP)

(similarity relation)

Binárna relácia:

$$S_R : A, B \subseteq X \rightarrow [0;1]$$

$s \in [0;1]$ index podobnosti



Vlastnosti:

1. Reflexivnost' $(\forall x \in X : (x, x) \in S)$
2. Tranzitívnost' $(\forall x, y, z \in X : (x, y) \in S \wedge (y, z) \in S \Rightarrow (x, z) \in S)$
3. Symetričnosť $(\forall x, y \in X : (x, y) \in S \Rightarrow (y, x) \in S)$

Typy RP:

1. Aritmetický priemer
2. Skalárna mohutnosť (*počet prvkov množiny*)
3. Suprénum (maximum)

1. Minkowského metrika:

$$S_M(A, B) = \left(\sum_{i=1}^n |\mu_A(x_i) - \mu_B(x_i)|^r \right)^{1/r}; \quad r > 0$$

2. Hammingová metrika (*obsahy plôch*):

$$S_H(A, B) = \frac{\|A \cap B\|}{\|A \cup B\|}$$

\cap - min; \cup - max

3. Tverského metrika:

$$S_T(A, B) = \frac{f(A \cap B)}{f(A \cap B) + \alpha \cdot f(A - B) + \beta \cdot f(B - A)}; \quad \alpha, \beta \geq 0$$

f - ľubovoľná transformačná funkcia

Použitie:

- multikriteriálne rozhodovanie
- inferencia produkčných pravidiel (*5 najbližších susedov*)

Metóda piatich najbližších susedov

(Five Nearest Neighbors)

(k): Ak x_1 je LX_1^k & ... & x_n je LX_n^k Potom u je LU^k

1. Výpočet vzdialenosí

$$\begin{array}{cccc} x_1, & x_2, & \dots & x_n \\ \downarrow & \downarrow & & \downarrow \\ s_1^k, & s_2^k, & \dots & s_n^k \\ \uparrow & \uparrow & & \uparrow \\ LX_1^k, & LX_2^k, & \dots & LX_n^k \end{array}$$

$$d_k = \frac{1}{f(s_1^k, s_2^k, \dots, s_n^k)}$$

d_k – vzdialosť vstupov od
predpokladov pravidla k
 f – agregačná funkcia

2. Výber piatich pravidiel s najmenším d_k
3. Zoradenie pravidiel $d_i < d_j$ ($d_{max}=d_5$)
4. Výpočet absolútnych váh:

$$w_{abs_i} = \frac{d_{max} - d_i}{d_{max}}; \quad w_{abs_i} \in [0;1]$$

5. Výpočet relatívnych váh:

$$w_{rel_i} = \frac{w_{abs_i}}{\sum_{i=1}^5 w_{abs_i}}; \quad \sum_{i=1}^5 w_{rel_i} = 1$$

6. Výpočet výstupnej FP LU_c :

$$\mu_{LU_c} = \sum_{i=1}^5 w_{rel_i} \cdot \mu_{LU^i} \quad *$$

Alternatíva k inferencii podľa jednotlivých pravidiel

RP

FR

s \approx kompatibilita (*singletonová fuzzifikácia*)

w_{rel} \approx normalizovaná α

f \approx agregačnej funkcie

* $\approx \begin{cases} T_I & \text{- produkt} \\ S_A & \text{- suma} \end{cases}$

Hranové (lingvistické) operátory

Termy:

- atomické (*starý, mladý*)
- zložené (*stredne starý*, *veľmi teplý, trochu, presne, viac menej, ...*)

Príslovky *p* posúvajú, spresňujú alebo rozostrujú význam atomického termu.



Hranové operátory využiteľné ako sémantické pravidlo v definícii lingvistickej premennej.

Modifikácia atomických termov A operátormi f_H :

$$\mu_{pA}(x) = f_H(\mu_A(x))$$

Typy hranových operátorov:





1. Koncentrácia $f_C(x)$ – spresnenie pojmu,

t.j. zúženie FP, $\mu_{pA}(x) \subset \mu_A(x)$

2. Dilatácia $f_D(x)$ – rozostrenie pojmu,

t.j. rozšírenie FP, $\mu_{pA}(x) \supset \mu_A(x)$

3. Intenzifikácia $f_I(x)$ – kompromis medzi $f_C(x)$ a $f_D(x)$




Typy modifikačných funkcií f_H :

1. Mocninové: $\mu_{pA}(x) = f_M(\mu_A(x)) = \mu_A(x)^k$
(veľmi k=2, viac menej k=0,5)

2. Posuvné: $\mu_{pA}(x) = f_P(\mu_A(x)) = \mu_A(x-s)$
s – posun, nutnosť uvažovať typ hrany

3. Normované: $\mu_{pA}(x) = f_N(\mu_A(x)) = \mu_A(c.(x-r)+r)$
c – normalizačný faktor
Normované sú špeciálnym prípadom posuvných.



$$f_I(\mu_A(x)) = \mu_A((x - r)^{C_c} + r)^{C_d}$$

C_c – koncentrácia, C_d - dilatácia

Multidimenzionálne fuzzy uvažovanie

Jednodimenzionálne fuzzy uvažovanie:

Ak x je A Potom y je B
(jeden vstup - jeden výstup)

Ak x_1 je A_1 & x_2 je A_2 & ... & x_n je A_n Potom u je B

Problém: Agregácie T_A je t-norma vykonávajúca prienik medzi FM definovanými na tom istom univerze.

FM vstupných premenných ale nie sú definované na tom istom univerze!!!

Metódy multidimenziálneho uvažovania

1. Kartézsky súčin
2. Miera podobnosti (*relácie podobnosti*)
3. Lineárna interpolácia
4. Pravdivostné (*truth*) funkcie

1. Mizumoto (kartézsky súčin)

Ak x_1 je A_1 & x_2 je A_2 & ... & x_n je A_n Potom u je B

Nech platí:

x_1 je A'_1 & x_2 je A'_2 & ... & x_n je A'_n

Potom (*modus ponens*): u je B'

Uvažujme dvojrozmerný prípad:

Ak x_1 je A_1 & x_2 je A_2 Potom u je B

x_1 je A'_1 & x_2 je A'_2

u je B'

a) $A_1, A_2 \subseteq X$ (to isté univerzum)

$$A = A_1 \cap A_2 = T_A(A_1, A_2)$$

b) $A_1 \subseteq X_1, A_2 \subseteq X_2$ (rôzne univerza)

Riešenie: cylindrické rozšírenie A_1, A_2 , t.j. $\text{ce}(A_1), \text{ce}(A_2)$

$$\begin{aligned} \text{ce}(A_1) &= A_1 \times X_2 \\ \text{ce}(A_2) &= X_1 \times A_2 \end{aligned} \quad \left. \right\} \subseteq X_1 \times X_2 = X$$

Ako v a):

$$x_1 \in A_1 \quad \& \quad x_2 \in A_2 = \text{ce}(A_1) \cap \text{ce}(A_2) = \text{ce}(A)$$

$$\text{ce}(A) = T_A(\text{ce}(A_1), \text{ce}(A_2))$$

Ak \wedge & \vee sú konjugované a pre \Rightarrow platí:

$$(A_1 \wedge A_2) \Rightarrow B \equiv (A_1 \Rightarrow B) \vee (A_2 \Rightarrow B) \quad (*)$$

Potom:

$$x_1 \in A_1' \wedge x_2 \in A_2' \Rightarrow y \in B'$$



$$x_1 \in A_1' \Rightarrow y \in B_1'$$

\vee



$$B' = B_1' \vee B_2' = S(B_1', B_2')$$

$$x_2 \in A_2' \Rightarrow y \in B_2'$$

(*) platí pre - I_{KD} , I_O , I_{Gd} , I_L

Dôsledok: Jedna n -dimenzionálna inferencia sa nahradí n jednodimenzionálnymi inferenciami.

2. Tsukamoto

Ak x_1 je A_1 & x_2 je A_2 & ... & x_n je A_n
Potom u je B

Dekomponuje sa na n jednorozmerných pravidiel:

Ak x_i je A_i Potom u je B

x_i je A'_i

u je B'_i

$$B' = B'_1 \cap B'_2 \cap \dots \cap B'_n$$

Problém:

Ak pre I platí: $(A_1 \wedge A_2) \Rightarrow B \equiv (A_1 \Rightarrow B) \vee (A_2 \Rightarrow B)$,
potom $B' = B'_1 \cup B'_2 \cup \dots \cup B'_n \neq$ Tsukamoto

3. Nafarieh & Keller (*podobnosť & pravdivosť*)

Stupeň kompatibility (*miera podobnosti*):

$$mp_H(A, A') = \frac{|A \cap A'|}{|A \cup A'|} \quad (\text{Hammingova metrika})$$

Operátory kompatibility:

- \cap - T_C
- \cup - S_C

Majme: $M = \int_0^1 (\mu_{\text{pravdivý}}(x))^k dx$

M - fuzzy pravdivostná hodnota, miera že $A' \Rightarrow B$

Majme: $M = f(mp_H(A, A')) =$

$$= \begin{cases} mp_H(A, A'). \int_0^1 \mu_{pravdivy}(x) dx, & \text{ak } A \subset A' \\ \frac{1}{mp_H(A, A')} \cdot \int_0^1 \mu_{pravdivy}(x) dx, & \text{ak } A \supseteq A' \end{cases}$$

Ak $x_1 \in A_1 \wedge x_2 \in A_2 \wedge \dots \wedge x_n \in A_n$ Potom $u \in B$

Nech platí:

$x_1 \in A'_1 \wedge x_2 \in A'_2 \wedge \dots \wedge x_n \in A'_n$

$$mp_H(A_i^{'}, A_i) = \frac{|A_i^{'} \cap A_i|}{|A_i^{'} \cup A_i|}$$

Úlohou je najst' mocninu k_i z:

$$M_i = \int_0^1 (\mu_{pravdivy}(x))^{k_i} dx = f(mp_H(A_i^{'}, A_i))$$

$$k = \min_{i=1,\dots,n} k_i = T_A$$

$$\mathcal{B}' = \mathcal{B}^k \quad (výsledok)$$

Ak:

$$M_i = \int (\mu_{pravdivý}(x))^0 dx \quad \text{neurčitý}$$

$$M_i = \int_0^1 (\mu_{pravdivy}(x))^2 dx \quad \text{velmi pravdivy}$$

3



Možnosť popísat' B' aj slovne.

Príklad

Pravidlo: Ak x_1 je malá (A_1) & Ak x_2 je veľká (A_2)
Potom u je stredná (B)

Vstupy: Ak x_1 je celkom malá (A_1'); x_2 je veľká (A_2')

$$\mu_{malá} = \begin{cases} 1, & x < 1 \\ -0.25 \cdot x + 1.25, & 1 \leq x \leq 5 \\ 0, & x \geq 5 \end{cases},$$

$$\mu_{stredná} = \begin{cases} 0, & x < 2 \text{ alebo } x > 10 \\ 0.25 \cdot x - 0.5, & 2 \leq x \leq 6 \\ -0.25 \cdot x + 2.5, & 6 < x \leq 10 \end{cases},$$

$$\mu_{veľká} = \begin{cases} 0, & x < 8 \\ 0.5 \cdot x - 4, & 8 \leq x \leq 10 \\ 1, & x > 10 \end{cases}.$$

celkom malá = malá^{0,5} (Baldwinov systém)

$$\mu_{celkom\ malá} = \begin{cases} 1, & x < 1 \\ [-0.25 \cdot x + 1.25]^{0.5}, & 1 \leq x \leq 5 \\ 0, & x \geq 5 \end{cases}$$

Nech: $\mu_{pravda}(x)=x$ $\rightarrow T_k = \int_0^1 (\mu_{pravda}(x))^k dx = \frac{1}{k+1}$


- $mp_H(A_2, A_2')=1$
- $mp_H(A_1, A_1') = \frac{\int_0^1 \mu_{malá}}{\int_0^1 \mu_{celkom\ malá}} = \frac{1 + \int_1^5 [-0.25 \cdot x + 1.25] dx}{1 + \int_1^5 [-0.25 \cdot x + 1.25]^{0.5} dx} = \frac{1 + 2}{1 + 8/3} \doteq 0.82$
- $A_1 \subset A_1'$

$$f[mp_H(A_1, A_1')] = mp_H(A, A') \cdot \int_0^1 \mu_{pravda}(x) dx = 0.82 \cdot \int_0^1 x dx = 0.82 \cdot 0.5 = 0.41$$

- $$\begin{aligned} \frac{1}{k_1+1} &= 0.41 & \rightarrow k_1 &= 1.44 \\ \frac{1}{k_2+1} &= 0.5/1 & \rightarrow k_2 &= 1 \end{aligned} \quad \left. \right\} \Rightarrow k = k_2 = 1$$



$$B \approx B'$$



4. Sugeno & Takagi (*lineárna interpolácia*)



Potreba mať aspoň 2 pravidlá, aby sa dal odvodiť fakt ležiaci medzi nimi:

Ak x je veľké Potom y je malé


Ak x je malé Potom y je veľké



Ak x' je [malé; veľké] Potom y' je [malé; veľké]



Prípad pre 2 vstupy:



A: $x \in A_1 \& y \in B_1 \rightarrow z \in C_{11}$

B: $x \in A_1 \& y \in B_2 \rightarrow z \in C_{12}$


C: $x \in A_2 \& y \in B_1 \rightarrow z \in C_{21}$

D: $x \in A_2 \& y \in B_2 \rightarrow z \in C_{22}$

Ak: $\begin{array}{l} A' \in [A_1; A_2] \\ B' \in [B_1; B_2] \end{array} \quad \} \quad \rightarrow \quad \begin{array}{l} \underline{(x \in A' \& y \in B')} \\ z \in C = ? \end{array}$

Postup:


- 1: Do A : dosad' y je B' , t.j. x je A_1 & y je B' $\rightarrow z$ je C_{11}'
- 2: Do B : dosad' y je B' , t.j. x je A_1 & y je B' $\rightarrow z$ je C_{12}'
- 3: Z 1 a 2: x je A_1 & y je B' $\rightarrow z$ je $D_1 = S_A(C_{11}', C_{12}')$
- 4: Pre x je A_2 & y je B' $\rightarrow z$ je $D_2 = S_A(C_{22}', C_{21}')$



Napr.: $D_1 = (C_{11}' + C_{12}')/2$
 $D_2 = (C_{21}' + C_{22}')/2$

T_A – obdoba akumulácie
 $(C_{11}' = T_I(C_{11}, B'))$

- 5: Do 3: dosad' x je A' , t.j. x je A' & y je $B' \rightarrow z$ je D_1'
- 6: Do 4: dosad' x je A' , t.j. x je A' & y je $B' \rightarrow z$ je D_2'
- 7: x je A' & y je $B' \rightarrow z$ je $C = S_A(D_1', D_2')$



Napr.: $C = (D_1' + D_2')/2$

Pozn.:

- Vzťah x_1 je A_1 & x_2 je $A_2 \rightarrow y$ je B nie je chápaný ako implikácia ale ako funkcia $y = f(x_1, x_2)$.
- Postup výpočtu sa podobá na lineárnu interpoláciu.
- Vyhodnotenie pravidla s n vstupmi sa rozloží na na jednodimenzionálne vyhodnocovanie v n krokoch.
- Je možné riešenie aj „inverzného“ problému:
Je známe x_2 a y . Treba vypočítať x_1 (*modus tollens*).

Systémy pravdivostných hodnôt

Do akej miery je pravda že:

40km/h vysoká rýchlosť v obci;

50 rokov stredný vek;


7 stupňov Celzia nízka teplota?



Miera kompatibility, resp. pravdivosti výroku: x je F

T – priestor pravdivostných hodnôt $t \in [0; 1] = T$
(pravdivostný priestor)

Výhoda: Možné transformovať rôzne univerzá do jedného (T).



$$T(F) \in T = [0; 1]$$

$T(F)$ – kompatibilita x a F = pravdivostná hodnota

Pozn.:

Prav. hodnoty majú slovné a aj číselné vyjadrenie (ostré alebo fuzzy).

Negácia: $T(\neg F) = 1 - T(F) \Leftrightarrow$ nepravda verzus pravda.

Ak singletonová fuzz. $\Rightarrow T(F_i) = T_c(x_i, F_i)$ (c – kompatibilita).


Baldwinov systém

Systém pevne definovaných 9 pravdivostných hodnôt:
pravdivý (P), nepravdivý (N), veľmi pravdivý, veľmi nepravdivý, celkom pravdivý, celkom nepravdivý, úplne pravdivý, úplne nepravdivý, nerozhodný.

- Exponenciálna rodina pravdivostných hodnôt.
- Závisí od definície pojmu *pravdivý* (monotónne rastúci) a hodnôt exponentov.
- Bod pretnutia medzi *P* a *N* je vždy 0.5.
- Použité hranové operátory.
- Číselné prav. hodnoty ako ostré čísla.
- Ak $k \rightarrow \infty \Rightarrow \text{veľmi}^k \rightarrow \text{úplne}.$
- Ak $k \rightarrow -\infty \Rightarrow \text{celkom}^{1/k} \rightarrow \text{nerozhodne}.$

Pre $\mu_{pravdivý}(t)=t$:

| | | | |
|--------------------|---------------|---|--|
| Nepravdivý: | $\mu_N(t)$ | = | $1 - t$ |
| Veľmi pravdivý: | $\mu_{VP}(t)$ | = | t^2 |
| Veľmi nepravdivý: | $\mu_{VN}(t)$ | = | $(1 - t)^2$ |
| Celkom pravdivý: | $\mu_{CP}(t)$ | = | $t^{0.5}$ |
| Celkom nepravdivý: | $\mu_{CN}(t)$ | = | $(1 - t)^{0.5}$ |
| Úplne pravdivý: | $\mu_{UP}(t)$ | = | $\begin{cases} 1, & t = 1 \\ 0, & \text{inak} \end{cases}$ |
| Úplne nepravdivý: | $\mu_{UN}(t)$ | = | $\begin{cases} 1, & t = 0 \\ 0, & \text{inak} \end{cases}$ |
| Nerozhodný: | $\mu_{NR}(t)$ | = | 1 |



Zadehov systém

- Vie generovať ľubovoľný počet pravdivostných hodnôt (*pravdivý, nepravdivý, nie pravdivý, veľmi pravdivý, nie veľmi pravdivý, viac alebo menej pravdivý, skôr pravdivý, nie veľmi pravdivý a nie veľmi nepravdivý, ...*).
- Číselné pravdivostné hodnoty budú ostré alebo FM.
- Gramatiky (syntaktické pravidlá) → názvy.
- Hranové operátory (sémantické p.) → funkcie.

$$\mu_P(t) = \begin{cases} 0, & 0 \leq t \leq a \\ 2 \cdot \left(\frac{t-a}{1-a}\right)^2, & a \leq t \leq \frac{1+a}{2} \\ 1 - 2 \cdot \left(\frac{t-1}{1-a}\right)^2, & \frac{1+a}{2} \leq t \leq 1 \end{cases}$$

a – minimálna príslušnosť

Možné použiť podobné definície funkcií ako u Baldwina, pokiaľ číselné prav. hodnoty $T(F)$ sú ostré.

Ak sú fuzzy, t.j. $T(F) = \{\mu_1(t_1)/t_1 + \mu_2(t_2)/t_2 + \dots + \mu_n(t_n)/t_n\}$.

$$\mu_{\neg F}(t) = \mu_1(t_1)/(1-t_1) + \mu_2(t_2)/(1-t_2) + \dots + \mu_n(t_n)/(1-t_n) = 1 - \mu_F(t)$$

Avšak podľa definície:

$$\mu_N(t) = \mu_1(1-t_1)/t_1 + \mu_2(1-t_1)/t_2 + \dots + \mu_n(1-t_1)/t_n$$

$$\mu_{\neg F}(t) \neq \mu_N(t)$$




$\mu_{\neg F}(t)$ – nie pravdivý

Pozn.:

Mochinové hranové operátory modifikujú stupne príslušnosti pri tých istých hodnotách univerza.

Pravdivostné operátory modifikujú hodnoty univerza pri tých istých hodnotách stupňov príslušnosti.



Fuzzy systémy

Zhluková analýza


Miery neurčitosti FM

Fuzzy množiny typu 2

Druhy neurčitosti – prehľad

Zhluková analýza

Čo je zhlukovanie?



Zhluky (clusters)

Prvky sú si „niečím“ podobné.

Nekontrolované učenie, hľadanie štruktúry v dátach.

Ciel:

- Zoradiť do skupín „neoznačené“ (unlabeled) dát.
- Nahradíť množstvo dát ich menším počtom reprezentantov.

Čím sú si prvky podobné?

- vzdialenosťou – hľadanie minimálnej vzdialosti
- konceptom – napr. kusy nábytku, ovocie, zelenina...

Typy vzdialostného zhľukovania:

1. Výlučné (tvrdé) – patrí / nepatrí (iba 1 zhľuk)
2. S prekrytím (mäkké) – príslušnosť k viacerým zhľukom (fuzzy)
3. Hierarchické – vytváranie podzhľukov a nadzhľukov
4. Pravdepodobnostné

Požiadavky na zhlukovací algoritmus

- škálovateľnosť – pre n rozmerné vzorky,
- práca s rôznymi typmi veličín,
- tvorba zhlukov rôznych tvarov,
- všeobecnosť - minimálne špecifické znalosti o danej doméne,
- schopnosť práce so šumom,
- interpretovateľnosť a použiteľnosť výsledkov.

K-means


Výlučné zhlukovanie
MacQueen – 1967

$$\min \sum_{j=1}^k \sum_{i=1}^n \|x_i^j - c_j\|^2$$

x_i – údaj, $i = 1, \dots, n$
 c_j – zhluk, $j = 1, \dots, k$ ($k < n$)

Algoritmus:

1. Vyber k údajov (vzoriek) a označ ich za centrá zhlukov.
2. Prirad' každú vzorku do najbližšieho zhluku (najmenšia vzdialenosť).
3. Vypočítaj nové pozície centier zhlukov ako priemery pozícii vzoriek zhluku.
4. Opakuj kroky 2 a 3, pokiaľ sa centrá zhlukov menia.



Fuzzy C-means

Zhlukovanie s prekrytím, mäkká forma K-means
Dunn – 1973, Bezdek – 1981 (vylepšený)

$$\min \sum_{j=1}^C \sum_{i=1}^n w_{ij}^m \|x_i^j - c_j\|^2$$

w_{ij} – váhy príslušnosti (μ) vzorky x_i k zhluku c_j
 m – fuzzifikátor, $m \in [1; \infty]$


Algoritmus:

1. Inicializuj maticu $W^0 = [w_{ij}]$.
2. V každom kroku k vypočítaj centrá zhlukov c_j^k a maticu váh W^k .
3. Opakuj krok 2 pokial' sa neprestane meniť matica W .


$$c_j = \frac{\sum_{i=1}^n w_{ij}^m \cdot x_i}{\sum_{i=1}^n w_{ij}^m}$$

$$w_{ij} = \frac{1}{\sum_{k=1}^C \frac{\|x_i - c_j\|^2}{\|x_i - c_k\|^{m-1}}}$$

Porovnanie K-means a Fuzzy C-means





K-means



Fuzzy C-means

Miery neurčitosti FM



Ktorá FM je viac „fuzzy“?


$\mathcal{P}(X) = 2^X$ – potenčná množina $\forall \text{FM} \subseteq X$

Miera neurčitosti - všeobecne

$d: \mathcal{P}(X) \rightarrow \mathbb{R}^+$

Pre $A, B \in \mathcal{P}(X)$ musí platiť:

1. Ak FM A je konvenčná množina, potom $d(A)=0$.
2. $d(A) + d(B) = d(A \cup B) + d(A \cap B)$.
3. Ak pre $\forall x \in X$ platí $\mu_A(x)=0,5$, potom $d(A)$ je maximálna.
4. Ak vždy platí jedna z podmienok:
 - (a) $\mu_A(x) \leq \mu_B(x) \leq 0,5$,
 - (b) $\mu_A(x) \geq \mu_B(x) > 0,5$,potom $d(A) \leq d(B)$.



Čím je FM viac neurčitá (fuzzy), tým menej informatívna.

Všeobecný tvar neurčitosti

$$d(A) = F(arg) = F \left(\sum_{\forall \alpha \in (0;1]} |A^\alpha| \cdot f(\alpha) \right) *$$

F – neklesajúca funkcia, $F(0)=0$

$|A^\alpha|$ – mohutnosť α hladiny

f → miery entropie

→ miery energie

Neurčitosť závisí viac od stupňov príslušnosti, než od prvkov univerza.

Miery typu entropie:

1. $f(0)=f(1)=0$.
2. Existuje α_0 , pre ktoré $f(\alpha_0)$ je maximálna.
3. Pre $\forall \alpha_1$ a α_2 platí:

$$\begin{aligned}\alpha_1 \leq \alpha_2 \leq \alpha_0 &\rightarrow f(\alpha_1) \leq f(\alpha_2), \\ \alpha_0 \leq \alpha_1 \leq \alpha_2 &\rightarrow f(\alpha_1) \geq f(\alpha_2).\end{aligned}$$

Hammingová miera:

$$f(x) = \begin{cases} x, & x \in [0; 0.5) \\ 1 - x, & x \in [0.5; 1] \end{cases} \implies *$$

$$\text{Hm}(A) = \sum_{\forall x} | \mu_A(x) - A_{0.5}(x) |$$

$A_{0.5}(x)=1$, ak $x \in A_{0.5}$ (α -rez); ináč $A_{0.5}(x)=0$.

Euklidovská miera:

$$f(x) = \begin{cases} x^2, & x \in [0; 0.5) \\ (1-x)^2, & x \in [0.5; 1] \end{cases} \implies *$$

$$\text{Eu}(A) = \sqrt{\sum_{\forall x} (\mu_A(x) - A_{0.5}(x))^2}$$

Entropická miera:

$$f(x) = -x \cdot \log x - (1-x) \cdot \log(1-x) \implies *$$

$$\text{En}(A) = \sum_{\forall x} [-\mu_A(x) \cdot \log \mu_A(x) - (1-\mu_A(x)) \cdot \log(1-\mu_A(x))]$$

Normalizované miery – $d(A) \in [0; 1]$:
Eliminujú vplyv mohutnosti nosiča FM.

$$U = \bigcup_{\forall i} \text{supp}(LX_i)$$

$$\overline{Hm}(A) = \frac{2}{|U|} Hm(A)$$

$$\overline{Eu}(A) = \frac{2}{\sqrt{|U|}} Eu(A)$$

$$\overline{En}(A) = \frac{1}{|U| \cdot \log 2} En(A)$$

Miery typu energie:

$f(0)=0$ a $f(1)=1.$

Napr.:

$$\text{Sq}(A) = \sum_{\forall x} (\mu_A(x))^2$$

Pozn.:

Miery typu entropie sú necitlivé na prvky s rovnakým stupňom príslušnosti. Tu sú lepšie miery energie.

Fuzzy množiny typu 2


L.A. Zadeh - 1975

Umožňujú zohľadniť viac stupňov príslušnosti pre daný prvok univerza, t.j. „*fuzzifikácia fuzzy*“.


$$\tilde{A} = \left\{ \left(x, \mu_{\tilde{A}}(u_x) \right), \quad \forall x \in X, u_x \in U \right\}$$

u_x – interval hodnôt stupňov príslušnosti pre x

Všeobecná fuzzy množina typu 2 (neurčitosť 2. rádu)



Intervalová fuzzy množina typu 2 (neurčitosť 1. rádu)




Pozn.: Odpadá potreba 3. rozmeru pre $\mu_{\tilde{A}}(U_X)$.

Pozn.:

- Intervalové FM typu 2 redukujú zložitosť matematiky všeobecných FM na prácu s dvomi klasickými FP (DFP a HFP).
- Všetko, čo platí pre klasické FM, platí aj pre FM typu 2 a naopak.
- Klasické FM sú špeciálnym prípadom, tzv. FM typu 1, ak u_x je jednoprvkový interval.
- Je možné zovšeobecnenie na FM typu n ($n=1, 2, \dots$).
- FM typu 2 dokážu zohľadniť odlišnosť názorov viac expertov na význam pojmov a výstupy pravidiel.
- FM typu 2 modelujú aj nestacionárny šum (FM typu 1 modelujú stacionárny šum).


FR s intervalovými FM typu 2



FM typu 1 vyjadruje mieru neurčitosti ostrého výstupu.

Druhy neurčitostí

- Pravdepodobnosť (probability)
- Príslušnosť (fuzzy)
- Možnosť (possibility)
- Nutnosť (necessity)
- Presvedčenie, viera (belief)
- Prijateľnosť, prípustnosť (plausibility)
- **Istota (confidence)**
- ...



Koniec!

Ďakujem za pozornosť.

